

重点回答

一.

RadixAttention主要用于解决处理出现**大量共享前缀**的场合，通过类似于**记错题本**的方式减少冗余处理

二.

前者类似于page attention，在**物理层的显存管理**上作用；后者则实现radix attention的部分功能，在**逻辑层的prefill**上作用

三.

page attention用以解决**显存碎片化**的问题

pageattention	radixattention
vLLM	SGLang
物理优化	逻辑优化

两种机制是允许共存的

在SGLang中有使用部分的pageattention；在vLLM中使用哈希表而非基底树来实现减少反复前缀处理量的功能

