

阅读文献笔记

vLLM

page attention 机制

-定义：切割KV Cache为块,按需分配缓存以减少显存浪费的机制

优势

- 显存浪费极低
- 高并发吞吐量

SGLang

radix attention 机制

- 定义：通过Radix Tree智能处理公用前缀，减少重复计算的机制（打比方说就是记录错题本，遇到原题就略过）
- 通过RadixCache等实现

优势

- TTFT（Time To First Token）低
- 多轮对话中缓存命中率高

pageattention与RadixAttention的横向对比

pageattention	radixattention
vLLM	SGLang
物理优化	逻辑优化

两种机制是允许共存的

在SGLang中有使用部分的pageattention；在vLLM中使用哈希表而非基底树来实现利用反复前缀的功能

